

Análisis de Capacidad. Entrega No. 3 Desarrollo de Soluciones Cloud

Grupo 5: Jairo Céspedes Plata, María Catalina Ibáñez, José Manuel Moreno, David Saavedra Martínez Contexto del proyecto

El proyecto sobre el cual se adelantarán los análisis de capacidad y pruebas, descritos a continuación tiene como principal propósito la conversión de archivos de distintos formatos mediante un servicio web. En consecuencia, resulta necesaria la ejecución de un análisis de capacidad. El siguiente análisis de capacidad hace parte de la tercera entrega de documentación acerca de la herramienta desarrollada hasta la fecha.

Herramientas para el análisis:

Para llevar a cabo el análisis de capacidad exhaustivo se utilizó una máquina local en Bogotá, Colombia que ejecute la herramienta de carga JMeter.

La selección de la máquina y la herramienta se dio debido a la facilidad que ofrece la interfaz de JMeter en Windows y la conexión por cable ethernet (300Mb con servicio de fibra óptica) que posee la máquina local; las especificaciones se ilustran en la Imagen 1. Por otra parte, vale mencionar que se ha decidido utilizar la herramienta JMeter, ya que es un framework ampliamente conocido, así como por la gran cantidad de documentación disponible.



Imagen 1. Capacidad de la máquina local.

La configuración de los parámetros de JMeter, consideró el ajuste del número de hilos, el tiempo de rampa y otras variables relevantes para simular cargas realistas en el sistema. Adicionalmente, se diseñaron escenarios de prueba detallados y realistas para abordar diferentes aspectos críticos del sistema.

Criterios de medición de desempeño

Como marco general para la construcción de las pruebas se tuvo la metodología GSM (Goal, Signal, Metric) desarrollada por Google [1]. Dicho enfoque permite construir mediciones basadas en las necesidades del proyecto que podrán variar a lo largo del tiempo y no realizar el proceso inverso de fijar métricas arbitrarias para luego ajustar las pruebas.

Como principales criterios están la carga y la conversión explicados a detalle en la tabla 1.

Tabla 1. Criterios para la construcción de pruebas

GOAL SIGNAL METRIC



Carga	carga de archivos de manera	Cuando un usuario intenta cargar un archivo, la	en menos de 25 seg
	eficiente.	plataforma está disponible y	(Throughput) y nivel del
		funciona de manera rápida.	error del 0.1%.
Conversión	Los documentos convertidos	Cuando un usuario realiza	99.9% de los archivos deben
	deberán ser correctos y	una conversión recibe el	ser correctos y procesar al
	procesados de manera	documento correcto y de	menos 0.5 archivos por min.
	rápida.	manera rápida.	

Tabla 1. Fijación de métricas estimadas.

Adicionalmente y buscando brindar mayor robustez se presentan criterios de aceptación para ejecutar los escenarios de carga con características y técnicas mejor definidas.

Escenarios de prueba:

- 1. Carga de Archivos:
 - Se simulará la carga de archivos en el sistema mediante solicitudes HTTP utilizando datos de prueba que reflejen la diversidad de archivos que podrían ser cargados por los usuarios en la aplicación (archivos con extensión .docx, .xlsx y .pptx). Se evaluará la capacidad del sistema para manejar archivos de 1 MB, así como la concurrencia de varios archivos cargándose simultáneamente (con 0 seg de diferencia entre cada uno).
 - Estos *requests* deberían responderse en promedio, en menos de 25 segundos. En el caso que el tiempo establecido sea superado, se considerará que el sistema perdió rendimiento y la aplicación llegó a su límite. La cantidad máxima de archivos será aquella en la que no degrade ese tiempo de respuesta. Por lo tanto, se espera que, en promedio, se logre subir 1 archivo por segundo, aunque esto también podrá depender, para efectos de la prueba. Además, se espera que la carga de archivos no supere una utilización de RAM de alrededor del 50% en el file-server; esto dado que se puede cargar un archivo, mientras se está convirtiendo otro a PDF, por lo que se necesita capacidad disponible para esta operación.
 - Finalmente, se espera que el 99.9% (% de error del 0.1%) de los archivos logren ser cargados exitosamente
 - Parámetros de Jmeter: La configuración final para las pruebas de carga de archivos implicará realizar ajustes en la cantidad de hilos (threads) para encontrar un equilibrio entre el rendimiento y la tasa de error. Se realizarán varias pruebas con diferentes cantidades de hilos (200, 190, 180, 170, 160), hasta que arrojen una tasa de error aceptable (del orden del 0.1%).
- 2. Procesamiento de Archivos a PDF y métricas de desempeño:
 - Se simulará el procesamiento de archivos para convertirlos a formato PDF, una operación crítica en el flujo de trabajo de la aplicación. Se medirá el tiempo necesario para procesar cada archivo y se evaluará la capacidad del sistema para manejar cargas de trabajo intensivas



considerando factores como el tamaño y la complejidad de los archivos, así como la disponibilidad de recursos del sistema.

- Se estimará la cantidad de archivos con extensión .docx, .pptx y .xlsx que fue capaz de convertir a pdf, después de que se lancen las tareas en 1 minuto, mediante una cola de mensajes, cada documento cargado debe pesar 1 Mb.
- Se espera que la tasa de error sea menor al 0.1% y que se logre procesar 0.5 archivos por minuto. Si alguno de estos SLOs es superado se considerará que el sistema perdió rendimiento y la aplicación llegó a su límite
- Parámetros de Jmeter: La configuración final para las pruebas de carga de archivos implicará realizar ajustes en la cantidad de hilos (threads) para encontrar un equilibrio entre el rendimiento y la tasa de error. Se realizarán varias pruebas con diferentes cantidades de hilos (50, 10, 5), hasta que arrojen una tasa de error aceptable (0%) y una tasa de 0.5 archivos por minuto, de forma ideal.
- Cada prueba se va a ejecutar al menos 3 veces para evitar el sesgo estadístico y se anotarán los resultados de cada una, finalmente sacar conclusiones más específicas como:
 - Cantidad de archivos subidos al API sin afectar el tiempo de respuesta de menos de 5 segundos.
 - Cuántos archivos es capaz de convertir el sistema en menos de 1 minuto siendo de diferentes tipos (.docx, .pptx y .xlsx) y de un tamaño de 1Mb.
 - Comportamiento de las métricas en un escenario de estrés (utilización CPU y RAM, capacidad de procesamiento y tiempo de respuesta).

3. Desarrollo de las pruebas:

3.1. Prueba #1 - Carga de Archivos

La configuración final para las pruebas de carga de archivos implicó realizar ajustes en la cantidad de hilos (threads) para encontrar un equilibrio entre el rendimiento y la tasa de error. Al realizar varias pruebas con diferentes cantidades de hilos (200, 190, 180, 170, 160), se determinó que utilizar unos 160 hilos para cada tipo de archivo, arrojaba la menor tasa de error para ese conjunto de tamaños de muestras, dicha tasa fue del orden del 0.21%. Sin embargo, vale resaltar que no se logró una tasa de error inferior al límite preestablecido del 0.1%.

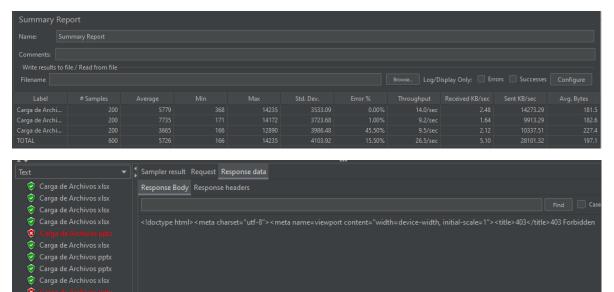
Los resultados promedio de estas pruebas indicaron un rendimiento con un promedio throughput de 20.46/segs, con lo cual como se advirtió, **no se logró el objetivo de tener una tasa de error inferior al 0.1%**. Sin embargo, como se explica en el desarrollo de las pruebas, este resultado se tendría en parte o podría atribuirse a una aparente limitación de GCP, donde ésta última, tendría una limitación



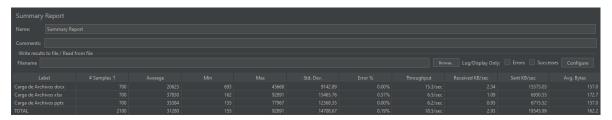
para más de 150 hilos, no porque la máquina virtual tuviera algún problema de procesamiento o capacidad, si no por alguna condición de no permitir subir más de 150 hilos.

A continuación, se detalla el paso a paso realizado para lograr estos resultados:

• Pruebas utilizando 200 hilos (threads) por cada tipo, para 3 tipos diferentes de archivos (docx, xlsx, pptx); sin embargo, el % de error subió del 0.1% (15.5%) así que se descarta, debido a que el mismo Google Cloud Storage niega tantas peticiones al mismo tiempo.



• Pruebas utilizando 190 hilos (threads) por cada tipo, para 3 tipos diferentes de archivos; sin embargo, el error es superior al 0.1%, se obtuvo el 10.88% así que se descarta, debido a que el mismo Google Cloud Storage niega tantas peticiones al mismo tiempo.

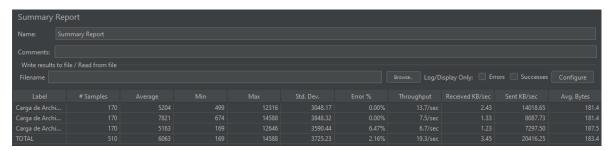


• Pruebas utilizando 180 hilos (threads) por cada tipo, para 3 tipos diferentes de archivos; sin embargo, el error es superior al 0.1%, se obtuvo un % de error que subió del 0.10% así que se descarta (6.48%), debido a que el mismo Google Cloud Storage niega tantas peticiones al mismo tiempo.



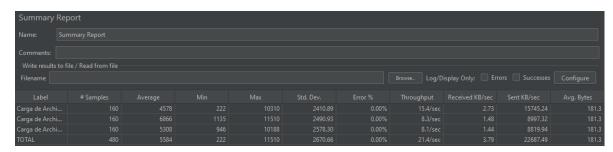


• Pruebas utilizando 170 hilos (threads) por cada tipo, para 3 tipos diferentes de archivos; sin embargo, el error es superior al 0.1%, se obtuvo como % de error que subió del 0.10% así que se descarta (2.16 %), debido a que el mismo Google Cloud Storage niega tantas peticiones al mismo tiempo.



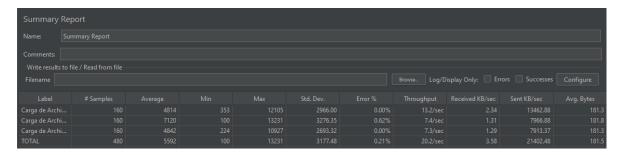
• Finalmente se realizaron pruebas utilizando 160 hilos (threads) por cada tipo: Se hizo para 3 tipos diferentes de archivos. Al ejecutar 3 iteraciones, el error se mantiene por debajo del 0.1%. Al finalizar, se registró un error % promedio del 0.21% y un promedio de throughput= 20.46/seg

- Iteración 1:

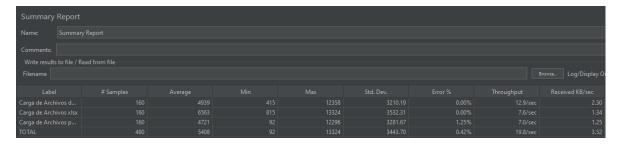


Iteración 2:

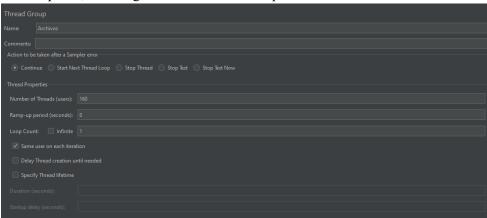




- Iteración 3:



En este punto, la configuración asociada a las pruebas considerando 160 hilos fue:





Vale mencionar que la VM-web server, no excedió el 50% de uso de CPU y se comportó de la siguiente manera:





3.2. Prueba #2 - Procesamiento de Archivos en la conversión a PDF y métricas de desempeño

Para las pruebas en el procesamiento de archivos durante la conversión, la configuración final también requirió ajustes en la cantidad de hilos a considerar. En primera instancia se evaluaron 50 hilos, obteniendo como resultado una tasa de error superior al 98% (solo 3 tareas se transformaron de 150), esto debido a que al parecer el worker no deja crear más tareas de procesamiento y solo realiza esas 3 y para el resto simplemente no les realiza procesamiento.

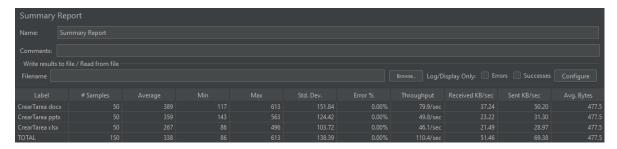
Ante este resultado, se consideró un número inferior de hilos para mejorar el desempeño en la prueba. Sin embargo, al considerar 10 hilos por tipo de archivo, la herramienta lograba una transformación de 9 archivos de 141, con una tasa de error del 94%. Lo cual sigue siendo una tasa muy alta de error.

Se volvió a ajustar el número de hilos a 5, donde al cabo de 1 minuto se presentaron 0 trabajos finalizados – transformados.

A continuación, se detalla el paso a paso realizado para lograr estos resultados:

• Pruebas utilizando 50 hilos (threads) por cada tipo, para 3 tipos diferentes de archivos; sin embargo, pasado 1 minuto, se transformaron muy pocas tareas.





• Al cabo de 1 minuto se arroja un XML el cual muestra que, de las 150 tareas, unas 3 se transformaron en ese periodo de tiempo:

• Mientras que 147 siguen en Uploaded.

```
> uploaded Aa ab. * 1 of 147 ↑ ↓ ≡ x

<?xml version="1.0" encoding="UTF-8"?>

<testResults version="1.2">

<httpSample>

<responseData class="java.lang.String">[{&quot;input_file_path&quot;:&quot;uploads/prueba1docx_3.docx&

</httpSample>

</testResults>
```

Se observa que el worker escaló:





• Se procede a bajar el número de hilos a 0 threads por cada tipo de archivo. Dado que se obtuvo que 3/150= 0.02 tareas procesadas por minuto y el objetivo es lograr que se tenga: 0.5 tareas por minuto. Aunque, en este caso, al esperar 10 minutos, se obtuvo que 9 fueron exitosos y 141 fallaron, por lo tanto, hay un % de error del 94%, un valor bastante alto. Vale resaltar que lo que sí se cumple es que de esos 3, al obtener el estado processed y el resto ser uploaded implica que el 100% de los archivos que se transformaron en ese tiempo lo hicieron exitosamente.

Pruebas con 10 threads por cada tipo de archivo:

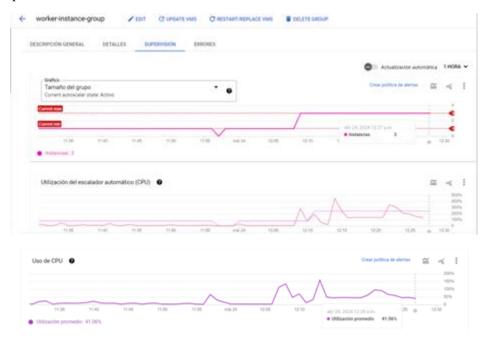


Y al cabo de 1 minuto arroja un XML el cuál muestra que de las 30 tareas, 0 se transformaron en ese periodo de tiempo:

• 30 siguen en Uploaded implicando que ninguno ha sido error.



El worker quedó así, donde se nota que no existió algún problema de capacidad o procesamiento con la Máquina Virtual:

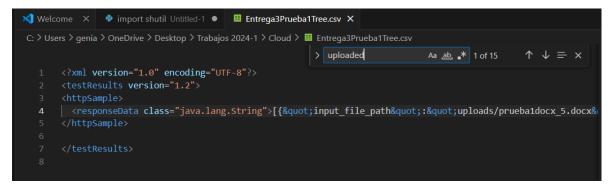


- Al final, se obtuvo una tasa de 0/30 = 0 archivos por minuto, por lo tanto, se evaluará el reducir la cantidad de tareas ya que el worker se está viendo saturado.
- Pruebas con 5 threads, para los 3 tipos de archivos:
- Iteración 1:





• Y al cabo de 1 minuto arroja un XML el cual muestra que, de las 15 tareas, 0 se transformaron en ese periodo de tiempo:



Resultado Iteración 1: Tasa de 0 archivos transformados por minuto.

El Worker registró lo siguiente:

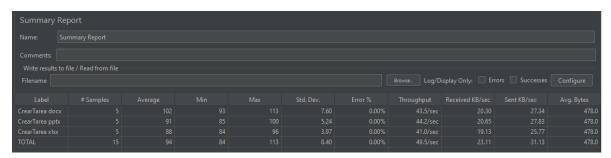






Donde se obtuvo que el % de error es del 100% ya que los 15 archivos fueron no procesados (al cabo de 10 min).

- Iteración 2:

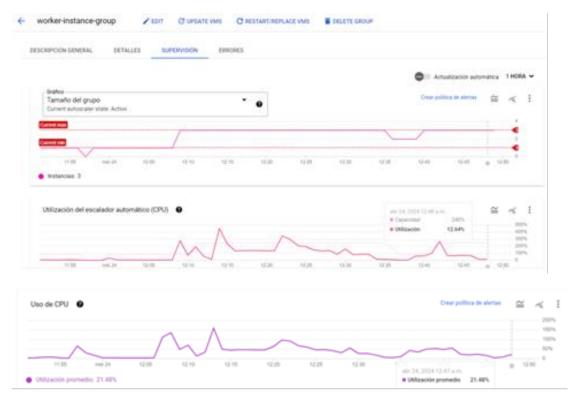


• Y al cabo de 1 minuto arroja un XML que muestra que, de las 15 tareas, 0 se transformaron en ese periodo de tiempo (hay 30 porque están las 15 anteriores):

Resultado Iteración 2: Tasa de 0 archivos transformados por minuto.

El Worker registró:





Donde se obtuvo un % de error del 100% ya que los 15 archivos no fueron procesados (al cabo de 10 min)

RESULTADO FINAL: No se realiza otra prueba debido a que el error ya es del 100% en todos los casos

Datos finales con 5 threads por cada tipo de archivo:

Promedio de archivos por minuto de las 2 pruebas= 0

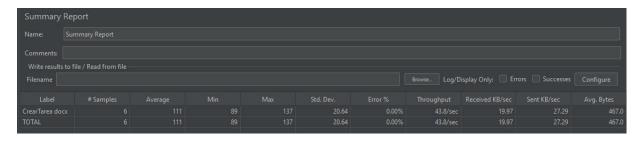
Promedio de % de error al minuto= 100%

Promedio de % de error a los 10 min= 100%

Como caso extra se realizó una modificación para ver si se solucionaba el problema del worker, se empezó con 2 workers iniciales escalables a 3 para ver si el procesamiento se corregía, con un máximo de CPU del 55%:

• Pruebas con 6 threads, para 1 tipo de archivo "*.docx", el cual tiene un tamaño de 433kb. Sin embargo, de las 6 tareas a procesar en 1 minuto, solo procesó 1.







Como se puede apreciar, no es un problema directo de la escalabilidad del worker sino relacionado al procesamiento interno de este.

CONCLUSIONES FINALES GENERALES:

En términos generales, al realizar el conjunto de pruebas, la solución desarrollada no logró el cumplimiento de los indicadores de calidad o de desempeño predefinidos. Esto, a pesar de los múltiples escenarios planteados, por ejemplo: con diferentes números de tareas a procesar, e incluso con varios tamaños de archivos, puede concluirse que las métricas de desempeño obtenidas no fueron las esperadas, debido a algún problema de transición de Celery a lo que se está usando actualmente para hacer la transformación de los archivos.

Aunque las tareas se procesaron, lo hicieron en menor escala o tiempo de lo esperado y, además, la tasa de error fue superior al valor predefinido del 0,1 %. Esto puede ser atribuible, en parte, a una limitación que se encontró en GCP para procesar más de 150 hilos-tareas.

Por otro lado, vale la pena rescatar y resaltar que, durante las pruebas, el escalamiento SÍ operó, donde inicialmente se tenía un escalamiento de 1 a 3 MV, también se utilizó la opción de empezar con 2 Workers hasta llegar a 3, pero al parecer el problema no es debido al escalamiento.

Bibliografía

[1] Software Engineering at Google (abseil.io)